Detectarea originii textelor în limba română

SDCGIA, tema 6 · Experiment v3 · 23 octombrie 2026

1. Scop și corpus

Am adaptat Qwen3.5-4B cu Unsloth pentru clasificarea binară a articolelor în umane sau generate de AI. Corpusul complet conține 7.950 de texte: 4.524 umane și 3.426 AI. Articolele provin din arhiva UNIMEDIA din 2018. Proveniența istorică susține eticheta umană, fără a certifica independent autoratul.

Am inclus toate textele ne goale, fără prag de lungime sau echilibrare forțată. Am eliminat duplicatele exacte și variantele aceleiași surse. Generarea a folosit Ollama, llama.cpp și interfața ChatGPT. Numele modelelor web reprezintă etichetele înregistrate în interfață, nu identificatori API verificați.

Partiție	Uman	AI	Total
Antrenare	3166	2391	5557
Calibrare	679	515	1194
Test	679	520	1199
Total	4524	3426	7950

Separarea folosește sursa și componentele de similitudine lexicală, cu seed 3407. Același articol-sursă și variantele sale AI rămân într-o singură partiție. Verificările nu găsesc suprapuneri de surse, grupuri sau texte normalizate exacte între partiții. Gruparea lexicală nu garantează independență semantică completă.

2. Generarea textelor

Prompturile în română folosesc tema, data de referință și entități candidate extrase din articol. Nu furnizează corpul articolului, titlul original sau o listă de fapte esențiale. Numerele și datele candidate pot transmite totuși informație contextuală. Fișierul generare/prompturi.jsonl păstrează cele 3.426 de cereri și parametrii disponibili. Pentru interfața web, setările numerice neexpuse rămân necunoscute.

3. Adaptarea detectorului

Model de bază în 4 biți, LoRA cu rang 16 și alpha 16, plus cap de decizie. Aproximativ 64,5 milioane de parametri antrenabili, adică 2,10%. Antrenare pe Tesla T4: o epocă, 348 pași, batch 1 și acumulare 16, learning rate 0,0002, scheduler cosine. Context 12.288 tokeni, fără trunchiere. Calea explicită K/V permite atenție eficientă pe T4. Antrenarea a continuat din checkpoint-100 după întreruperea sesiunii.

Rezultatele experimentului v3

4. Calibrare și evaluare

Calibrarea folosește numai cele 1.194 de exemple dedicate. Acuratețea raportată pe acest lot este 99,916%, cu ECE 0,000223 și loss 0,012662. Pragul rămâne fix la 0,5, fără optimizare pe test. Predictorul primește exclusiv textul și întrebările fixe. Etichetele și metadatele servesc doar la evaluare.

Origine reală / predicție	Uman	AI
Uman	679	0
AI	0	520

Test: 1.199/1.199 clasificări corecte, acuratețe 100%. Recall AI 100%, rata fals pozitive 0%, rata fals negative 0%. Brier: 0,000001038. Log-loss: 0,000640641. ECE cu 10 intervale: 0,000640117.

Intervalele Wilson 95% sunt 99,267%-100% pentru recall AI și 0%-0,563% pentru rata fals pozitive. Aceste intervale descriu incertitudinea binomială și nu corectează dependența reziduală între evenimente.

Model-sursă (eticheta înregistrată)	AI detectate / test	Uman asociat	FP / FN
GPT-5.6 Luna Light	15 / 15	15	0 / 0
GPT-5.6 Sol	15 / 15	15	0 / 0
GPT-5.6 Terra Light	15 / 15	15	0 / 0
GPT-6 Astra Light	15 / 15	15	0 / 0
GPT-6 Luna Light	15 / 15	15	0 / 0
GPT-6 Sol Light	15 / 15	15	0 / 0
GPT-6.1 Sol Light	15 / 15	15	0 / 0
gemma3:1b	34 / 34	34	0 / 0
gemma3:270m	24 / 24	24	0 / 0
qwen2.5-0.5b-instruct-q4_k_m	31 / 31	31	0 / 0
qwen2.5-1.5b-instruct-q4_k_m	31 / 31	31	0 / 0
qwen2.5-3b-instruct-q4_k_m	31 / 31	31	0 / 0
qwen2.5:1.5b	8 / 8	4	0 / 0
qwen2.5:3b	8 / 8	4	0 / 0
qwen3.5:0.8b	132 / 132	129	0 / 0
qwen3.5:2b	83 / 83	83	0 / 0
qwen3.5:4b	33 / 33	33	0 / 0

Controalele umane sunt cele asociate surselor AI din fiecare grup. Același control poate apărea în mai multe grupuri, deci rândurile tabelului nu se însumează. Cele două texte pilot ChatGPT cu model neidentificat nu apar între sursele AI ale testului. Rezultatele complete sunt în rezultate/test_metrics.json și per_model.csv.

Interpretare și reproducere

5. Ce demonstrează rezultatul

Detectorul separă perfect clasele în acest test intern. Verificarea locală a predicțiilor reproduce matricea de confuzie și metricile salvate pentru toate cele 1.199 de rânduri. Acest rezultat nu demonstrează că detectorul identifică universal autoratul AI.

Corpusul provine dintr-o singură publicație, iar generatoarele din test apar și în antrenare. Surse evaluate în experimente anterioare intră în noua împărțire. Prin urmare, testul v3 este exploratoriu, nu un test extern complet neatins. Diferențele de stil, formatare, lungime sau vocabular pot simplifica sarcina. Nu am măsurat separat contribuția acestor indicii.

Scorul 100% nu permite un clasament al generatoarelor. Unele grupe au numai 8 sau 15 texte AI. O verificare viitoare ar trebui să folosească articole umane din alte publicații și texte de la generatoare absente din antrenare, cu lungimi și formatare comparabile.

6. Fișierele livrate

notebook.ipynb: versiunea pentru o rulare nouă în Colab. date/SDCGIA_date_complete_v3.zip: textele, partițiile, proveniența și runtime-ul. generare/: cererile, modelele, setările și scriptul opțional pentru generare locală. rezultate/: notebookul executat, predicțiile, metricile și configurația originală. prezentare/: slideurile și fișa de susținere.

7. Rulare în Colab

Deschide notebookul din repository într-o sesiune T4 nouă. Datele se descarcă automat din GitHub și se verifică prin SHA-256. Montează propriul Drive pentru salvări. Rulează prepare până la secțiunea 5, apoi pilot până la 7. Repornește între faze. Pentru antrenare: RUN_MODE="train", CONFIRM_FULL_TRAINING=True și RESUME_CHECKPOINT=None. Păstrează RUN_NAME între faze. După finalizare, calibrează, activează testul și creează arhiva finală.

Pipeline-ul v3 a rulat pe GPU pentru rezultatele istorice. Adaptarea de livrare cu descărcare automată a fost verificată local pentru sintaxă, integritatea datelor și metrici, fără o nouă antrenare GPU integrală. Modelul de bază nu are revision fixată în run_config.json. Versiunile externe și hardware-ul pot afecta reproducerea exactă. Arhiva modelului și rapoartelor, de 332,28 MiB, rămâne separat de repository-ul cu date și cod.

Surse

Unsloth: https://unsloth.ai/docs/basics/train-your-own-decision-model-with-unsloth
Notebookuri originale: https://github.com/unslothai/notebooks
Date: UNIMEDIA, https://unimedia.info/ și URL-urile originale păstrate în proveniență.
Dovezi locale: rezultate/run_config.json, training_complete.json, calibration_metrics.json, test_predictions.jsonl și test_metrics.json.

Textele articolelor își păstrează drepturile surselor originale. Textele sintetice pot conține informații inventate. Materialele au scop academic.